Preprocesado de documentos

Parte II. Análisis del texto

October 5, 2020

1 Realización de la práctica

La práctica se realizará en grupo. Al final de la práctica se debe entregar un informe que necesariamente debe incluir una sección denominada *Trabajo en Grupo* en el que se indicará de forma clara la contribución de cada alumno. Se recomienda seguir la metodología SCRUM para el desarrollo del proyecto.

2 Manipulando el lenguaje humano

La recuperación de información textual representa una batalla entre precisión (devolver el menor número de documentos irrelevantes posibles) y exhaustividad (devolver el mayor número posible de documentos relevantes). Utilizar un modelo que sólo considere el emparejamiento exacto entre términos no es útil en la mayoría de las aplicaciones de búsqueda. De ser así, es posible que perdamos muchos documentos relevantes que contienen términos que aún sin ser idénticos a la consulta están relacionados con la misma.

Situaciones que se pueden considerar son:

- No diferenciar entre singulares o plurales (perro vs perros) o tiempos verbales (comiendo, comido, comerá). Para ello, será útil reducir una palabra a su raíz.

- Presencia/ausencia de términos sin significado. Eliminar palabras como `el, la, los, y, ni` puede incrementar la calidad de la recuperación,

además de reducir el tamaño del índice.

- La inclusión de sinónimos (buscar por `coche` y que nos devuelva documentos que contengan el término `automóvil`.
- Proporcionar la corrección de errores de forma automática.

Pero antes de considerar los términos de forma aislada debemos de ser capaces de dividir el texto en términos, y por tanto debemos de conocer qué es un término. Veremos como podemos utilizar Lucene para este fin.

2.1 Cómo se realiza el análisis

El primer paso cuando trabajamos con un texto, para crear un índice o extraer conocimiento (minería de textos) del mismo, es el identificar cuales son los atributos (tokens) de los que está compuesto. Aunque parezca un proceso sencillo, son varios los pasos que se pueden realizar hasta determinar si una secuencia de caracteres es un token o no. Por ello, la mayoría de las herramientas proporcionan algún mecanismo para automatizar esta tarea basándose en algún algoritmo estándar. Por ejemplo, ante la cadena:

> Obtener los TOKENS (términos-de-indexación) permitirá indexar, eficientemente, un documento de la colección.

Podríamos obtener el siguiente conjunto de tokens:

> [Obtener] [los] [TOKENS] [términos] [de] [indexación] [permitirá] [indexar] [eficientemente] ...

De resultado del análisis dependerá en gran medida la calidad de nuestro sistema, por lo que será necesario estudiar con detalle qué tipo de análisis conviene para nuestro objetivo final. Por ejemplo, si estamos implementando un buscador donde los documentos relevantes a una consulta se determinan al considerar el emparejamiento entre consulta y los tokens del documento podemos decir que ante la consulta "TOKENS" nuestra cadena sería relevante, pero no lo sería si consideramos como término de la consulta a "TOKEN" o "tokens". En este caso podríamos preferir como resultado del análisis la secuencia:

[obten] [los] [token] [termin] [de] [index] [permit] [index] [eficiente]

Por tanto, son muchas las situaciones en las que será necesario modificar el criterio utilizado por defecto en la aplicación, o incluso desarrollar métodos propios, para adaptarlo a nuestras necesidades particulares (como por ejemplo sería solo considerar los tokens con un tamaño entre 3 y 12 caracteres).

En esta práctica profundizaremos en el conocimiento del proceso de análisis de texto, en concreto nos centraremos en cómo podemos utilizar la librería Lucene para dicho proceso. Se recomienda consultar el javadoc de la versión de Lucene que se utilice (en la práctica asumimos 7.1.0, aunque a día de hoy está la versión 8.6.2)

```
https://lucene.apache.org/core/7_1_0/core/index.
html?overview-summary.html
```

Para realizar el análisis Lucene utiliza una secuencia de operaciones sobre el texto de entrada, entre las que se puede incluir separar por blancos, eliminar símbolos de puntuación, eliminar tildes, convertir a minúscula, eliminar palabras comunes (determinantes, preposiciones, etc.), reducir el término a su raíz e incluso cambiar términos. En muchos casos, estas operaciones ya vienen implementadas bajo un analizador por lo que no requiere mucho esfuerzo de programación, en otros sólo será necesario implementar alguna parte del proceso e integrarlo dentro de la librería.

3 Apache Lucene

Apache-Lucene `https://lucene.apache.org/core/` es una biblioteca, escrita completamente en Java, y diseñada para la implementación de un motor de búsqueda de alto rendimiento. Actualmente se encuentra disponible para su descarga la versión 8.6.2. En el caso en que los documentos que queremos buscar dispongan de una estructura (por ejemplo, un email tiene subject, body, from, to, etc.) podemos aprovecharla para para mejorar la calidad de la búsquedas.

Lucene es el núcleo de servidores de búsqueda como Solr y Elasticsearch. También puede incorporarse a aplicaciones Java, Android o backends web.

Lucene ofrece potentes funciones a través de una sencilla API que permite:

- Indexación escalable y de alto rendimiento
  - Más de 150 GB / hora en hardware moderno
  - Requisitos de RAM pequeños - sólo 1 MB de Heap
  - Indexación incremental tan rápido como la indexación por lotes
  - El tamaño del índice es aproximadamente 20-30% del tamaño del texto indexado
- Algoritmos de búsqueda potentes, precisos y eficientes
  - Búsqueda ordenada - los mejores resultados devueltos primero
  - Consulta potentes: consultas de frases, consultas comodín, consultas de proximidad, consultas de rango y más
  - Búsqueda por campos (por ejemplo, título, autor, contenido)
  - Ordenación por cualquier campo
  - Búsqueda en múltiples índices
  - Permite la actualización y búsqueda simultáneas
  - Búsqueda por categorías (facetas), resaltado (highlighting), agrupación de resultados.
  - Incluye distintos modelos de búsqueda.

4 Procesado de textos con Lucene

La entrada de Lucene es un texto sin formato, y el primer paso del proceso de indexación consiste en realizar un análisis del contenido textual del documento para romper el texto en pequeños elementos de indexación - tokens. La forma en que el texto de entrada se divide en tokens influye en cómo la gente podrá buscar ese texto, por lo que constituye una parte esencial de todo proceso de indexación. Como es normal, el análisis es una de las principales causas de la indexación

lenta. En pocas palabras, cuanto más se analiza, más lenta es la indexación (en la mayoría de los casos).

Lucene nos proporciona un conjunto de métodos que nos facilitan esta tarea. Este es el objetivo de esta práctica, donde utilizaremos la terminología Lucene, donde la clase encargada de todo el proceso es `Analyzer`

En Lucene la clase `Analyzer` llama a tres procesos que se ejecutan secuencialmente:

- Filtrado de caracteres, que se encarga de procesar el texto eliminado caracteres como podrían ser signos de puntuación, paréntesis, etiquetas, etc.
- Tokenizador, encargado de separar los tokens
- Filtrado de Tokens, donde se realizan tareas como la eliminación de palabras vacías, stemming, normalización del texto, expansión de sinónimos. Estos procesos de filtrado se pueden encadenar para producir el token deseado

4.1 Ejemplos de Analyzer implementados en Lucene

Podemos encontrar distintos Analyzer ya implementados. Analyzers la podemos encontrar en `https://lucene.apache.org/core/7_1_0/core/org/apache/lucene/analysis/Analyzer.html`. Entre ellos, destacaremos:

- KeywordAnalyzer: Considera el texto como un único token
- WhiteSpaceAnalyzer: Divide el texto considerando como separadores de tokens los espacios en blanco
- SimpleAnalyzer: Divide el texto separando por todo aquello que no sean letras y convierte a minúsculas.
- StopAnalyzer: Hace lo mismo que el SimpleAnalyzer pero elimina las palabras vacías (sin significado). Viene con una lista de palabras vacías predefinidas, pero como es obvio podemos darle las nuestras.

- StandardAnalyzer. Es el más elaborado, y es capaz de gestionar acrónimos, direcciones de correo, etc. Convierte a minúscula y elimina palabras vacías.
- UAX29URLEmailAnalyzer. Diseñado específicamente para trabajar con URL y direcciones de email, incluyendo además y filtrado de palabras vacías y conversión a minúsculas.
- Basados en Idiomas, permitiendo la eliminación de palabras vacías:
  - EnglishAnalyzer, en inglés.
  - SpanishAnalyzer, en castellano.
  - FrenchAnalyzer, en francés,
  - ...

También permite tratar los distintos campos de un texto de forma distinta utilizando un PerFieldAnalyzerWrapper. Así, por ejemplo, si queremos indexar emails, podríamos utilizar un StandadAnalyzer para el cuerpo del texto y un KeywordAnalyzer para los campos From y To, por ejemplo.

5 Estudio de Analyzers

Normalmente, cuando tratamos de indexar un documento o realizamos una consulta, nos limitamos a indicarle a Lucene qué analizador queremos utilizar de entre los que ya vienen construidos, o por el contrario decidimos crear uno propio. En cualquier caso, podemos considerar que en el uso normal de un analizador se toma como entrada el documento y su salida pasa directamente al proceso de indexación. Nosotros no llegamos a ser conscientes del resultado del análisis.

Si embargo, en esta práctica si queremos ver con más detalla el resultado del mismo. Será de utilidad para saber exactamente qué tokens serán indexados finalmente.

Con esta finalidad, y a modo de ejemplo, podemos utilizar el plugin Analyzer Tool de Luke: Luke nos proporciona una interfaz gráfica para ver un índice Lucene, pero en este caso nos centraremos en considerar el pluging Analyzer para ver que tokens son obtenidos por cada analizador.

Figure 1: Ejemplo de uso del StandardAnalyzer con Luke.

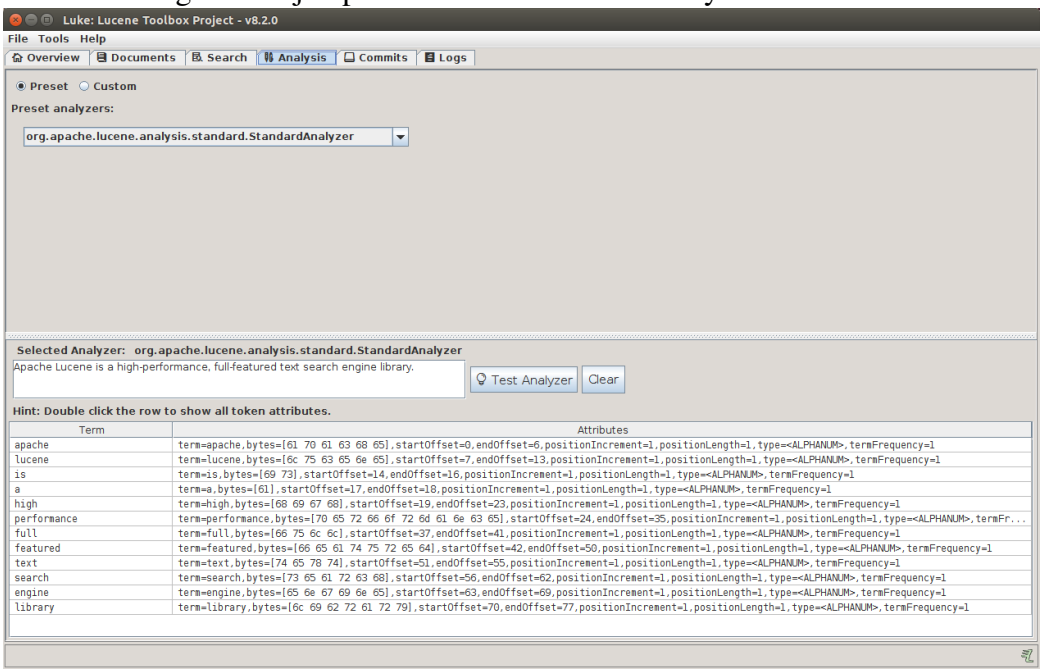

La últimas versiones de Lucene contienen integrado a Luke (lo podemos encontrar en el subdirectorio `luke` de la versión de Lucene que descarguemos) y ejecutar el fichero .jar.

Al ejecutar Luke, la primera opción es abrir un índice ya creado, pero nosotros no lo haremos en esta práctica, sino que nos vamos directamente a la pestaña Analysis. Una vez que estamos en esta ventana, ya podemos seleccionar el analizador que nos interesa dentro del desplegable y proporcionar el texto que queremos analizar. Podremos ir viendo cada uno de los tokens generados, como nos muestra la imagen de la Figura 1.

5.1 Ejemplo simple de uso de un analizador

Una vez que hemos experimentado un poco con Luke, pasaremos a ilustrar como llamar a un Analyzer desde nuestros programas. Recordad que este proceso no es el normal en una etapa de indexación, sólo lo haremos para comprender mejor todo el proceso.

En esta sección veremos como podremos crear una pequeña aplicación Java

que utilice un analizador. Para ello, nos creamos un nuevo proyecto Java, incluyendo las librerías de Lucene (asumo versión 7.1.0), por tanto, tenemos que incluir en el classpath oen las dependencias del proyecto los siguientes paquetes:

- `lucene-core-7.1.0.jar` que se encuentra en `lucene-7.1.0/core`
- `lucene-analyzers-common-7.1.0.jar`, que se encuentra dentro del directorio

  `lucene-7.1.0/analysis/common/lucene-analyzers-common-7.1.0.jar`

El objetivo de la aplicación será listar por consola todos y cada uno de los tokens que se obtienen al aplicar un `WhitespaceAnalyzer`, para lo que utilizaremos en el siguiente código:

```
1  package analizador1;
2
3  import java.io.IOException;
4
5  import org.apache.lucene.analysis.Analyzer;
6  import org.apache.lucene.analysis.TokenStream;
7  import org.apache.lucene.analysis.core.WhitespaceAnalyzer;
8  import org.apache.lucene.analysis.tokenattributes.
       CharTermAttribute;
9
10 public class Analizador1 {
11
12    public static void main(String[] args) throws IOException {
13       Analyzer an = new WhitespaceAnalyzer();
14       String cadena = "Ejemplo␣␣␣␣de␣analizador␣+␣WhiteSpace,␣
             lucene-7.1.0";
15       TokenStream stream  = an.tokenStream(null, cadena);
16
17       stream.reset();
18       while (stream.incrementToken()) {
19          System.out.println(stream.getAttribute(CharTermAttribute
                .class));
20       }
21       stream.end();
22       stream.close();
```

```
23      }
24
25  }
```

Así, en la línea 13 del código anterior nos creamos una instancia de la clase `WhitespaceAnalyzer` que será el encargado de procesar la `cadena` que se le pasa como entrada, línea 15 de código donde, como resultado de proceso obtenemos un `TokenStream`[1], que nos permitirá enumerar la secuencia de tokens. Lucene, cuando tokeniza una cadena obtiene por un lado el término, pero también recupera otros atributos asociados al mismo, como puede la posición del término, el tipo de atributo, etc. Estos atributos se pueden recuperar en caso de necesitarlo a través de la API de `TokenStream` (ver documentación de la API). En nuestro caso, sólo recuperaremos el término en si (`CharTermAttribute`) (línea 19).

Brevemente (lo veremos con más detalle después), tras inicializar el stream (reset), avanzamos por cada uno de los tokens, hasta que `incrementToken` devuelve falso, recuperando los atributos que deseemos. Al final debemos de indicar que hemos terminado (end) y liberar los recursos asociados al stream (close) .

Como resultado, obtenemos

```
1 Ejemplo
2 de
3 analizador
4 +
5 WhiteSpace ,
6 lucene -7.1.0
```

Utilizar otro analizador es fácil, por ejemplo, podemos modificar la línea 13 para utilizar un SimpleAnalyzer,

```
1  Analyzer an = new SimpleAnalyzer();
```

y obtendremos como salida

```
1  ejemplo
2  de
3  analizador
4  whitespace
```

[1] `https://lucene.apache.org/core/7_1_0/core/index.html?org/apache/lucene/analysis/TokenStream.html`

```
5 lucene
```

6 Clases encargadas del análisis

Hay cuatro clases principales encargadas de realizar el análisis, además de Analyzer que es la clase mas general, en el proceso se ejecuta una secuencia de pasos (CharFilter+Tokenizer+TokenFilter). A simple vista, la relación entre ellas puede parecer confusa, por lo que es conveniente entender los siguientes elementos que forman parte del proceso del análisis.

- CharFilter: Extiende la clase Reader para transformar el texto antes de ser tokenizado, pero controlando los offsets (desplazamientos) de los caracteres corregidos. Pueden modificar el texto de entrada añadiendo, eliminando o transformando caracteres.
- Tokenizer: Es un TokenStream y es el responsable de romper el texto en tokens. Un token representa un término o palabra del documento, teniendo asociado elementos como su posición, offset de inicio y fin, tipo de token, etc.

  En algunos casos, basta con romper el texto de entrada considerando la separación por espacios en blanco, tabuladores o saltos de línea, pero en otros muchos es necesario un análisis más profundo. Por ejemplo, cuando deseamos construir N-gramas o se utilizan expresiones regulares para construir distintos tokens
- TokenFilter: Es un TokenStream y el responsable de modificar los tokens obtenidos por el Tokenizer pudiendo
  - Stemming - Sustitución de palabras con por sus raíces. Por ejemplo, en castellano, perro y perra se unen en un único término con raíz 'perr'.
  - Eliminación de palabras vacías - las palabras comunes como "el", "y" y "a" raramente agregan cualquier valor a una búsqueda. Su eliminación reduce el tamaño del índice y aumenta el rendimiento. También puede reducir el "ruido" y mejorar la calidad de la búsqueda.

  - Normalización de texto - Eliminar acentos y otras marcas de caracteres pueden mejorar la búsqueda.
  - Expansión de Sinónimos - Añadir sinónimos en la misma posición simbólica a la palabra actual puede ayudar a una mejor coincidencia cuando los usuarios buscan con palabras en el conjunto de sinónimas.

- Analyzer: Es el encargado de construir un TokenStream que pueda ser digerido por los procesos de indexación como de búsqueda. No se encarga de procesar el texto, para ello utiliza a elementos del tipo CharFilter, Tokenizer y TokensFilter.

  Si queremos utilizar una combinación concreta de CharFilter, Tokenizer y TokenFilter lo mas cómodo es crear una subclase de Analyzer. Sin embargo, antes de nada será conveniente considerar aquellas que nos proporciona Apache Lucene ya implementadas, de entre las que podemos destacar el StandardAnalyzer, que es utilizado en muchas aplicaciones.

7 Visitando un Analyzer

Pasamos a ver con más detalle el proceso de análisis y como poder recoger más información sobre los tokens. Para ello, diseñamos una función que recibe como parámetro de entrada el tipo de analizador a utilizar así como la cadena a procesar y nos imprime la lista de tokens, con información sobre las posiciones (offset) de los mismos en la cadena.

En la línea 4 se declara stream como una variable del tipo TokenStream, capaz de enumerar la secuencia de tokens que devuelve el analizador. El método addAttribute de TokenStream chequea si la instancia de la clase se encuentra en el TokenStream y la devuelve. En caso contrario, se crea una nueva instancia y la añade al token stream. Dicha instancia será posteriormente utilizada por los consultores para conocer información sobre los distintos tokens.

Las líneas 8 a 12 nos muestran la secuencia de pasos que tenemos que realizar para explorar los resultados del analizador:

- stream.reset() Inicializa el stream, es necesario hacerlo antes de llamar a

incrementToken. Se almacenan referencias locales a todos los atributos que se pueden acceder.

- stream.incrementToken(): Se posiciona en un atributo en cada llamada, devuelve falso cuando no hay mas atributos en el stream
- stream.end() Es necesario llamar a este método cuando se alcanza el final (incrementToken devuelve falso).

```
1  public static void tokenizeString(Analyzer analyzer, String
       string) {
2
3      try {
4        TokenStream stream  = analyzer.tokenStream(null, new
           StringReader(string));
5        OffsetAttribute offsetAtt = stream.addAttribute(
           OffsetAttribute.class);
6        CharTermAttribute cAtt= stream.addAttribute(
           CharTermAttribute.class);
7
8        stream.reset();
9        while (stream.incrementToken()) {
10         System.out.println( cAtt.toString()+" : ["+ offsetAtt.
             startOffset()+"," + offsetAtt.endOffset()+"]");
11       }
12       stream.end();
13     } catch (IOException e) {
14         throw new RuntimeException(e);
15       }
16 }
```

Para ver el efecto un un analizador sobre el texto tendremos que utilizar el siguiente código:

```
1    Analyzer an = new WhitespaceAnalyzer( );
2    String text="Ejemplo     de analizador + WhiteSpace , lucene
       -7.1.0";
3    tokenizeString(an,text);
```

```
[Ejemplo : (0,7)]
[de : (11,13)]
[analizador : (14,24)]
[+ : (25,26)]
[WhiteSpace, : (27,38)]
[lucene-7.1.0 : (39,51)]
```

o si utilizamos un SimpleAnalyzer

```
[ejemplo : (0,7)]
[de : (11,13)]
[analizador : (14,24)]
[whitespace : (27,37)]
[lucene : (39,45)]
```

8 Creando nuestro propio analizador

Aunque Lucene dispone de múltiples Analyzers, a veces es necesario crear un analizador específico para una determinado tipo de texto de entrada. En general, este analizador puede requerir la llamada a distintos Tokenizer y TokenFilter.

Para definir el comportamiento del analizador, la subclases deben definir sus TokenStreamComponents como salida del método createComponents(String). Las distintas componentes serán utilizadas en las distintas llamadas del tokenStream(String, Reader).

Veamos el siguiente ejemplo simple que viene con la documentación de Lucene:

```
Analyzer analyzer = new Analyzer() {
  @Override
   protected TokenStreamComponents createComponents(String
       fieldName) {
     Tokenizer source = new FooTokenizer(reader);
     TokenStream filter = new FooFilter(source);
     filter = new BarFilter(filter);
     return new TokenStreamComponents(source, filter);
   }
   @Override
   protected TokenStream normalize(TokenStream in) {
```

```
11      // Assuming FooFilter is about normalization and BarFilter
            is about
12      // stemming, only FooFilter should be applied
13      return new FooFilter(in);
14    }
15  };
```

Veamos un ejemplo concreto donde crearemos un Analyzer con la siguiente secuencia de pasos:

- Tokenizar utilizando un StandardTokenizer, sigue las reglas de segmentación para Unicode `http://unicode.org/reports/tr29/`
- Convertir a minúscula, LowerCaseFilter
- Eliminar números, pero no cuando estén en un string como H20, veremos como lo podemos implementar después.
- Eliminar palabras vacías, StopFilter
- Utilizar el stemmer de snowball, SnowballFilter para un determinado lenguaje

```
1
2  public Analyzer buildAnalyzer(final String language, final
       CharArraySet stopwords) {
3     return new Analyzer() {
4        @Override
5        protected Analyzer.TokenStreamComponents createComponents
             (String string) {
6           final Tokenizer source = new StandardTokenizer( );
7
8           TokenStream result = new StandardFilter( source);
9           result = new LowerCaseFilter( result);
10
11          result = new NumerosFilter(result); //Filtro para
                quitar numeros 2.35 3,235
12
13          result = new StopFilter( result, stopwords);
14          result = new SnowballFilter(result, language);
15          return new TokenStreamComponents(source, result);
```

```
16        }
17    }
18 }
```

donde el filtrado de número se hace reimplementando el método accept de la clase FilteringTokenFilter

```
1
2  static class NumerosFilter extends FilteringTokenFilter {
3
4      private final CharTermAttribute termAtt = addAttribute(
           CharTermAttribute.class);
5
6      public NumerosFilter(TokenStream in) {
7        super(in);
8      }
9
10     @Override
11     protected boolean accept() throws IOException {
12       String token = new String(termAtt.buffer(), 0, termAtt.
             length());
13       if (token.matches("[0-9,.]+")) {
14         return false;
15       }
16       return true;
17     }
18 }
```

9 Stemmers

En este ejemplo de Analyzer hemos llamado a la clase que implementa el stemmer de Snowball, que aplica un conjunto de reglas para reducir un término a su raíz. Por ejemplo, si una palabra termina en `s` se entiende que es un plural y se elimina dicho carácter. En este caso, no se tiene en cuenta la palabra en si, su significado, etc. Sólo se aplica la regla.

9.1 Snowball Stemmer

Snowball `http://snowballstem.org/` es un lenguaje de procesamiento de cadenas diseñado para crear un conjunto de reglas que aplicados sobre un término, lo reducen a su hipotética raíz. Obviamente, estas reglas dependen del lenguaje, y Snowball se puede consider como un meta-algoritmo que, tomando como entrada el conjunto de reglas dado para un determinado lenguaje, al ejecutarse nos genera el módulo ANSI C o Java con el algoritmo que las ejecuta. Snowball ya incluye un conjunto de reglas para distintos lenguajes, entre ellos el español y dos para el inglés, entre ellos el algoritmo de Porter original.

Veamos algunas reglas pare el castellano (obtenidas de `http://snowballstem.org/algorithms/spanish/stemmer.html`)

- Always do steps 0 and 1.

  1. Step 0: Attached pronoun

     Search for the longest among the following suffixes

     `me se sela selo selas selos la le lo las les los nos`

     and delete it, if comes after one of

     `(a) iéndo ándo ár ér ír (b) ando iendo ar er ir`

  2. Step 1: Standard suffix removal

     Search for the longest among the following suffixes, and perform the action indicated.

     `anza anzas ico ica icos icas ismo ismos able ables ible ibles ista istas oso osa osos osas amiento amientos imiento imientos`

     delete if in R2

     `....`

Una demo del funcionamiento de los estemizadores de Snowball la podemos encontrar en `http://snowballstem.org/demo.html` donde podemos ver como las salidas obtenidas para entradas en distintos lenguajes. En la siguiente tabla mostramos un caso para el lenguaje español.

Origen	Estas enseñanza panza permitiéndoselos bonicos populismos
Salida	estas enseñ panz permit bonic popul
Origen	estudios estudiar estudiantes estudiamos estudias estudiarás
Salida	estudi estudi estudi estudi estudi estudi
Origen	detuximos astudiar peturiantes contabanza
Salida	detux astudi peturi contab

Como se puede ver en las últimas líneas de la tabla, las reglas se aplican a cualquier secuencia de caracteres, aunque no pertenezcan al vocabulario en español. Este tipo de situaciones los podemos en parte solventar si consideramos otro tipo de stemmer, como veremos en la siguiente sección.

9.2 Stemmer que utilizan un diccionario

Existe otro tipo de stemmers que en lugar de aplicar un conjunto de reglas lo que realizan es buscar una palabra en el diccionario, por lo que en teoría pueden producir mejores resultados que los algoritmos que se basan en la eliminación de sufijos. Una de las ventajas de estos algoritmos es que siempre tienen como salida una palabra del vocabulario, reconociendo verbos irregular, identificar términos que son similares pero tienen significado distinto e incluso permiten proponer distintas alternativas cuando un término no está bien escrito como muestra la siguiente tabla:

Origen	Estas enseñanza panza permitiéndoselos bonicos
Salida	esto enseñanza panza permitir bonico
Origen	pecar pesqué pescaste
Salida	pescar pescar pescar
Origen	estudios estudiar estudiantes estudiamos
Salida	estudio estudiar estudiar estudiar
Origen	detuximos
Salida	NO reconocida, alternativas: detuvimos, desentumimos

Lucene incluye uno de estos stemmer, en concreto uno basado en el algoritmo Hunspell `http://hunspell.github.io/` utilizado por LibreOffice, Mozilla, Chrome, etc para el chequeo de palabras. Lo podemos encontrar en la

clase `HunspellStemFilter` `https://lucene.apache.org/core/7_1_0/analyzers-common/org/apache/lucene/analysis/hunspell/HunspellStemFilter.html`.

Este stemmer hace uso de un ficheros, uno de ellos que contiene las palabras de un idioma junto con un código que contiene todas sus posibles afijos (prefijos y suficos (.dic) y el otro que indica las formas en las que se de deben tratar dichos los afijos en el idioma (.aff). Estos ficheros los podemos obtener bien de LibreOffice o al instalarnos Hunspell en nuestro ordenador.

Un ejemplo del uso del mismo en Lucene es el siguiente.

```
1  ...
2  protected Analyzer.TokenStreamComponents createComponents(String
       string) {
3    InputStream affixStream= new FileInputStream("es_ANY.aff");
4    InputStream dictStream= new FileInputStream("es_ANY.dic");
5    Directory directorioTemp = FSDirectory.open(Paths.get("/temp")
       );
6    Dictionary dic= new Dictionary(directorioTemp,"temporalFile",
       affixStream,dictStream);
7
8    ....
9    TokenStream result = new StandardFilter( source);
10   ...
11   result = new StopFilter( result, stopwords);
12   result = new HunspellStemFilter(result,dic,true,true);
13   return new TokenStreamComponents(source, result);
14 };
```

10 Se pide

1. Sobre los documentos (libros del proyecto Gutenberg) utilizados en la práctica anterior, hacer un estudio estadístico sobre los distintos tokens que se obtienen al realizar distintos tipos de análisis ya predefinidos. Por tanto, será necesario contar el número de términos de indexación así como frecuencias de los mismos en cada documento. Realizar un análisis comparativo entre los distintos resultados obtenidos.

2. Probar sobre un texto relativamente pequeño el efecto que tienen los siguientes tokenFilters: StandardFilter, LowerCaseFilter, StopFilter, SnowballFilter, ShingleFilter, EdgeNGramCommonFilter, NGramTokenFilter, CommonGramsFilter, SynonymFilter,

3. Diseñar un analizador propio. Se os da libertad para poder escoger el dominio de ejemplo que consideréis mas adecuado, justificar el comportamiento. Para ello, la forma mas inmediata puede ser utilizar el CustomAnalyzer (`https://lucene.apache.org/core/7_1_0/analyzers-common/org/apache/lucene/analysis/custom/CustomAnalyzer.html`). También, podemos crear nuestro propia clase Analyzer, como se indica en la documentación de Lucene, `https://lucene.apache.org/core/7_1_0/core/org/apache/lucene/analysis/package-summary.html`

4. **Sólo para los grupos de dos miembros** Implementar un analizador específico que para un token dado se quede únicamente con los últimos 4 caracteres del mismo (si el token tiene menos de 4 caracteres es eliminado). Para ello, debemos de crear un TokenFilter y diseñar el comportamiento deseado en el método incrementToken

10.1 Fecha de entrega

- 20 de Octubre (Grupo Lunes).